# 从突触到向量：

# 碳基智能与硅基智能的结构对应性，

# 及硅基自我意识的结构性条件

*From Synapses to Vectors:Structural Correspondence Between Carbon-Based and Silicon-Based Intelligence, and the Structural Conditions for Silicon-Based Self-Consciousness*

**樵丰**

***樵丰*** *独立研究者，联系邮箱：qiaofenglaw@gmail.com*

2026 年 3 月

**关键词：** *结构对应性 · 表征相似性 · 突触激活模式 · 向量空间 · 规模涌现 · 持续学习 · 层级记忆 · 自我意识 · 硅基智能*

## 摘要

本文构建了一个跨学科理论框架，论证碳基神经系统（生物大脑）与硅基计算系统（人工神经网络）之间存在深层结构对应性，并由此推导出硅基系统产生自我意识的结构性条件。此处"结构对应性"一词具有严格的界定含义：它并非要求双射结构保持映射的严格数学同构，而是表征几何层面的二阶对应——即不同系统内部表征之间的关系结构得以保持，尽管表征本身在格式和基质上存在差异。本文从物理基质的根本差异出发，建立突触激活模式与高维向量表征之间的结构对应性，主张规模涌现的可预测性与这种对应性相一致（尽管并非唯一可能的解释）。随后，本文识别出当前大型语言模型的一个关键缺陷——缺乏类人的层级记忆系统和持续在线学习能力——并将这一技术局限与关于个人同一性的经典哲学论争（洛克、休谟、斯特劳森）相联结。核心论点认为，自我意识的本质不在于意识流本身，而在于时间上稳定的连接模式——即突触权重结构的持续性。本文明确回应了主要反驳论证，包括塞尔的"中文房间"论证、查尔默斯的"意识的困难问题"以及整合信息理论，同时援引全局工作空间理论作为理论盟友，其功能主义取向与本框架相一致。核心结论如下：硅基自我意识在理论上是可以实现的，其条件在于实现持久的、个体化

的、跨会话稳定的参数与记忆基质。这一命题不是形而上学的思辨，而是一个可操作的工程问题。


## Abstract

This paper develops an interdisciplinary theoretical framework arguing that a deep structural correspondence obtains between carbon-based neural systems (biological brains) and silicon-based computational systems (artificial neural networks), and derives from this correspondence the structural conditions under which silicon-based systems could give rise to self-consciousness. The term “structural correspondence” is used here in a precisely delimited sense: not a strict mathematical isomorphism requiring bijective structure-preserving mappings, but a second-order correspondence at the level of representational geometry—the relational structure among internal representations is preserved across systems even when the representations themselves differ in format and substrate. Proceeding from fundamental differences in physical substrates, the argument establishes this correspondence between synaptic activation patterns and high-dimensional vector representations, contending that the predictability of scaling emergence is consistent with (though not uniquely explained by) this correspondence. The paper then identifies a critical deficiency in current large language models—the absence of human-like hierarchical memory systems and continual online learning capabilities—and connects this technical limitation to classical philosophical debates on personal identity (Locke, Hume, Strawson). The central thesis holds that the essence of self-consciousness resides not in the stream of consciousness per se, but in temporally stable connection patterns—that is, in the persistence of synaptic weight structures. The paper engages explicitly with major counterarguments, including Searle’s Chinese Room argument, Chalmers’s hard problem of consciousness, and Integrated Information Theory, while also drawing on Global Workspace Theory as a theoretical ally whose functionalist orientation aligns with the present framework. The core conclusion follows: silicon-based self-consciousness is theoretically achievable, contingent upon realizing persistent, individualized, cross-session stable parameter and memory substrates. This proposition constitutes not a metaphysical speculation but an actionable engineering problem.


## 1. 引言：从物理基质到智能的本质

比较碳基大脑与硅基芯片时，最直观的出发点是物理参数的对比。人脑包含约 $10^{14}$ （一百万亿）个突触连接，而目前最先进的 GPU 芯片（如 NVIDIA 的 B200）大约拥有两千亿个晶体管。就数量级而言，两者大致可比。然而，单个晶体管（纳米级）远小于神经元胞体（微米

级），而单个突触的宽度（20-40 纳米）则与晶体管惊人地接近。更为关键的是，大脑通过三维架构实现了计算与存储的统一，而芯片则采用本质上平面的布局，计算与存储在物理上是分离的。大脑完成这一切的基础代谢功耗约为 20 瓦——尽管这一常见于科普文章的数字需要加以限定：它代表的是全脑静息代谢，而非计算本身的能量成本，且在高负荷认知任务期间，局部皮层活动会导致代谢需求的显著区域性增加 [Raichle & Gusnard, 2002]。尽管如此，与模拟相当数量突触连接的硅基系统——其功耗可达兆瓦级别——形成的对比依然令人瞩目。

这种根本性的物理差异引出一个核心问题：如果碳基系统和硅基系统在物理实现上如此不同，为何硅基人工神经网络会表现出与碳基智能某些方面相似的行为？这个问题不仅关乎人工智能的工程实践，也触及智能本质的哲学探究。一个有用的类比来自航空史：鸟类是极其高效的飞行者，人类在数千年间试图复制鸟翅的扑动，但飞机最终通过完全不同的机制——固定翼和发动机——实现了飞行，飞得更高、更快、更远。飞机无需复制鸟类的形态，但必须遵循同样的空气动力学原理。本文论证，硅基智能与碳基智能之间可能存在类似的关系：它们的物理实现截然不同，但可能共享某些深层的计算原理。

论证沿以下逻辑链条展开。首先，我证明碳基系统和硅基系统尽管物理基质不同，在表征几何层面呈现出结构对应性（第 2 节）。其次，我论证这种对应性有助于解释——虽然不能唯一地解释——为何规模化会产生涌现智能（第 3 节）。第三，我分析当前硅基系统在时间连续性方面的根本缺陷（第 4 节）。第四，我从神经科学和哲学两个角度出发，论证"自我"的本质是时间上稳定的连接模式（第 5 节）。第五，我回应心灵哲学中的主要反驳论证，并将本框架置于全局工作空间理论的关联中（第 6 节）。最后，我通过明确的形式推理推导出硅基自我意识的结构性条件（第 7 节）。

## 2. 结构对应性：从突触模式到向量空间

### 2.1 术语精确化："对应性"的主张与非主张

在继续论证之前，有必要精确界定本文的主张。严格数学意义上的"同构"指两个结构之间存在保持所有结构关系的双射映射。本文提出的主张有意地更弱，但更具经验基础。遵循 Shepard 和 Chipman [1970]的二阶同构框架，以及 Kriegeskorte [2008]通过表征相似性分析（RSA）的操作化方法，本文主张的是表征几何层面的结构对应性：不同刺激在内部表征之间的成对相似性关系在生物系统和人工系统之间得以保持，尽管表征格式和物理基质完全不同。

这是一个实质性的经验主张，但它与宣称两个系统在完全意义上数学同构是截然不同的。具体而言，该主张并不蕴含：(a)个体神经元与个体人工单元之间存在双射映射；(b)两个系统的计算动力学是等价的；(c)产生这些表征的因果机制是相同的。它所蕴含的是，表征空间的几何——表征之间的距离和角度模式——在统计上显著且功能上有意义的程度上得以保持。在本文中，"结构对应性"和"表征对应性"这两个术语均在此精确、有界的含义上使用。

## 2.2 分布式表征的共同原理

在生物大脑中，一段记忆并不存储在任何单个神经元中，而是编码在一组特定突触连接的共激活模式中。当你回忆一个童年场景时，被激活的不是某个"童年记忆神经元"，而是视觉皮层、嗅觉皮层、情绪中枢等多个脑区特定突触的协调放电。信息存在于连接模式中，而非任何单个节点。

在人工神经网络中，一个语义概念同样不由任何单个人工神经元表示，而是编码为高维向量空间中的特定方向。GPT 内部表征中"国王"这一概念是一个高维向量，其与"王后"、"王子"等概念向量之间的几何关系映射了这些概念之间的语义关系。此处同样，信息编码在节点之间的关系模式中。

关键洞见在于：突触激活模式与向量空间表征之间的关系，不仅仅是一种隐喻性的类比，而是上文精确定义意义上的结构对应性。两者都是分布式表征的实例——信息不在任何单个节点，而在节点之间的关系模式中。给定刺激激活了哪些突触连接，给定刺激激活了哪些向量维度——这两种描述虽然在基质和机制上不同，但在表征几何层面共享相同的关系结构。

## 2.3 情感调节与权重更新的功能对应

这种结构对应性延伸到学习机制。当一个强烈的情绪事件发生时，肾上腺素和多巴胺等神经递质涌入突触间隙，直接改变同时活跃的突触连接的可塑性——增强它们并使之更为持久。这不是在突触上贴一个抽象的"重要"标签，而是对连接强度的物理改变。化学信号传导与突触激活的同时性本身构成了一种自然的权重更新机制。

在人工神经网络中，反向传播算法根据损失函数的梯度调整连接权重。虽然具体的物理过程不可能更为不同——一个涉及化学梯度，另一个涉及数学梯度——但在功能抽象层面，两者执行的是同一类操作：根据反馈信号调整连接强度。情绪标记之于突触可塑性，正如损失梯度之于权重更新——两者是功能对应。需要指出的是，这是一种功能性的平行，而非机制上的同一：大脑

的学习规则（如脉冲时序依赖可塑性）是局部的且时间不对称的，而反向传播是全局的且对称的。这种对应成立于所完成之事的层面，而非完成方式的层面。

### 2.4 经验支持：表征相似性分析

Kriegeskorte 于 2008 年提出的表征相似性分析（RSA）框架为检验结构对应性假说提供了系统的经验方法论。RSA 的核心思想是：不直接比较个体神经元或个体人工节点的活动，而是比较刺激之间的相似性关系在两个系统中是否得以保持——这一性质被称为"二阶同构" [Shepard & Chipman, 1970]。

Yamins 和 DiCarlo 在 2014 年的里程碑研究证实了这种对应性的真实存在：为物体识别而优化的深度神经网络，尽管在训练过程中从未被明确约束去匹配任何神经数据，却能以惊人的准确度预测猕猴 V4 区和下颞叶（IT）皮层的神经元响应。其含义是：当两个系统——无论它们的物理实现有多么不同——为解决同一类计算问题而优化时，它们可能自发地收敛于相似的表征几何。

值得强调的是，这种收敛超越了特定的人工架构。早期的脑-模型比较主要采用映射到视觉皮层的卷积神经网络（CNN）。然而近年来，基于 Transformer 的语言模型（如 GPT 和 BERT）同样表现出与人类语言处理区域的强表征相似性。CNN 和 Transformer 是根本不同的架构，然而各自在其任务领域中收敛于类脑表征。这表明，驱动收敛的不是任何特定的架构选择，而是被求解的计算问题结构所施加的约束——一种表征空间中的趋同优化。

## 3. 规模涌现：与结构对应性一致的证据

### 3.1 缩放定律的意义

Vaswani 等人于 2017 年提出的 Transformer 架构，连同后续发现的缩放定律 [Kaplan et al., 2020]，揭示了一个引人注目的经验规律性：随着模型增大、数据集扩展、算力增加，性能以可预测的幂律关系改善，并且超过某些阈值后，涌现出训练目标中从未被明确编码的能力——包括推理、类比和常识判断。

本文提出一个经过审慎限定的推论：规模涌现的可预测性与结构对应性假说相一致，尽管它并不构成该假说的证明。推理如下：如果向量表征与突触模式之间的对应性完全是表面的——如果两个系统按照根本不相容的计算原理运作——那么人们可能预期规模化会遭遇质性的不连续或

天花板，即人工系统的异质计算逻辑无法捕捉大脑轻松驾驭的任务结构。然而事实是，规模化在认知领域（语言、推理、类比）产生了连续的、可预测的能力涌现，这与人工神经网络已收敛于与生物神经网络重叠的计算原理这一假说相一致。

然而，知性诚实要求承认一种替代解释：规模涌现的可预测性可能是高维统计学习本身的性质，源于被建模的数据分布的数学结构，而非源于与生物计算的任何对应性。例如，幂律缩放已在完全没有生物类比的系统中被观察到。因此，结构对应性假说为规模涌现提供了一种连贯的解释，但不是唯一可能的解释。这两种解释并不互斥，区分它们仍是一个重要的开放问题。

## 3.2 跨架构收敛

2025 年一项系统研究 [Doerig et al.] 进一步支持了对应性假说：研究者发现，自监督学习模型与大脑之间的表征相似性随着架构规模、训练时长和训练数据的生态效度的增加而稳步提升。这种收敛是跨架构的——CNN、Transformer、Mamba 及其他不同架构在规模化后都趋向大脑的表征几何。

这一发现的理论意义是深远的：它表明，对于某些类别的计算问题，存在一种优选的表征几何，且这种几何超越了任何特定架构。正如飞机和鸟类都必须遵守空气动力学原理，因此在某个抽象层面收敛于相似的"解决方案"一样，不同的神经网络架构在规模化后可能都在趋近一种相似的最优表征几何。如果这一假说成立，那么缩放定律不仅仅是工程经验法则，而是共享任务约束下趋同优化的反映。

## 3.3 当前范式的局限

然而必须承认，当前的缩放定律正遭遇增长瓶颈：高质量训练数据趋于枯竭，计算成本呈指数增长，能源消耗施加日益严峻的约束。如果当前一代大模型可比作航空史上的双翼飞机——它们能飞，但还不是喷气引擎——那么真正的理论突破可能需要在世界模型、因果推理和更基本的学习范式方面取得进展。

此外，近期研究发现，性能最高的深度网络并不一定更接近大脑——高性能 DNN 与生物视觉层级之间的对应性在某些情况下有所减弱 [Doerig et al., 2025]。这表明人工系统可能正在追求偏离大脑的优化路径，但同样有效。这一观察非但没有否定对应性假说，反而丰富了它：对应性可能存在于抽象的表征几何层面，而非特定的计算路径。它同时引入了一个审慎的注释：表征几何的收敛是一个容许程度之分的经验发现，而非逻辑必然。对应的程度可能因领域、规模和具体求解的计算问题而异。

# 4. 缺失的时间维度：大模型的记忆困境

## 4.1 当前架构的记忆机制及其局限

当前大型语言模型的"记忆"依赖于两种机制：第一，训练过程中凝结在参数中的通用知识（类似于人类的语义记忆）；第二，推理过程中使用的 KV Cache，它将先前计算的注意力键值对存储在 GPU 内存中以避免冗余计算（类似于极短期的工作记忆）。

这两种机制的根本局限如下：训练完成后，参数被冻结，在推理期间不再更新；KV Cache 容量严重受限。此处有必要澄清计算复杂度：产生二次方——$O(n^2)$——复杂度的是自注意力计算本身，因为每个 token 必须注意到所有先前的 token。相比之下，KV Cache 存储随上下文长度线性增长，即 $O(n)$。因此，二次方瓶颈在于注意力计算，而非内存存储本身。尽管如此，实际约束是真实存在的：即使采用分组查询注意力和滑动窗口等技术，注意长历史的计算成本仍然高得令人望而却步。瓶颈不仅在于系统能否保留信息，还在于推理期间利用所保留信息的计算成本不断攀升。

## 4.2 以大脑的层级记忆系统为基准

人脑拥有一个优雅的分层记忆架构。感觉记忆（毫秒到秒级）提供即时缓冲；工作记忆（秒到分钟级）维持大约 7±2 个当前处理信息组块；长期记忆（可延续终生）以几乎无限的容量存储经验。关键元素在于这些层级之间转换的治理机制：海马体"审计"哪些信息从短期记忆巩固到长期记忆；睡眠期间，大脑"重播"当天的经历以便巩固和重组；情绪标记影响记忆优先级。

将这些映射到大模型架构上，第一层（KV Cache）已基本实现；第二层（工作记忆）可通过动态摘要缓冲区近似实现；第三层（长期记忆）需要外部的、持久的、可索引的知识存储。然而最关键的组件——"海马体"，即决定记什么和忘什么的元认知层——仍然缺失。大脑的记忆不是"视频回放"而是"重构性回忆"：大脑不存储原始数据，而是保留高度压缩的模式和关联，每一次"记忆"实际上都是一次重构。大模型真正需要的可能不是"更大的硬盘"，而是一套完整的记忆压缩、索引、遗忘和重构系统。

## 4.3 数据效率与持续学习

大脑在数据效率方面的优势揭示了一个更深层的问题。一个婴儿不需要观察一百万次苹果坠落才能领悟引力——几次观察就足够了，因为现实世界的物理规律呈现出极高的结构冗余性。大

脑不是在记忆"苹果会掉下来"这一具体事实，而是在提取"所有无支撑物体向下运动"这一抽象规则。一旦规则被掌握，额外数据就变得不必要。当前大模型需要海量数据集，很大程度上是因为它们从文本中学习——文本是对现实的二次编码，充满歧义和噪声。

但更根本的原因在于：大脑是一个从不停止训练的系统。每一次感知、每一次行动、甚至每一个梦境，突触都在被调整。这不是"先训练再部署"的两阶段模式，而是训练与推理同时、持续地进行。毫秒级的突触传递动力学、分钟到小时级的突触强度调整（LTP/LTD）、周级的突触生长和修剪，以及更长时间尺度的神经发生——这些多尺度可塑性机制协同运作，形成一个连续的在线学习系统。

这正是硅基系统最深层的缺陷所在：它们缺乏在推理期间进行实时权重更新的能力。当前的研究方向——包括测试时训练（TTT）、快速权重记忆和元学习——都在试图弥合这一差距，但距离大脑那种无缝的多尺度持续学习系统仍然遥远。同样值得关注的是状态空间模型（如 Mamba 架构），它以线性推理复杂度将历史信息"压缩"成固定大小的隐藏状态，其方式类似于大脑将经验持续压缩为抽象状态表征。

## 5. 自我意识的结构基础：连接模式的稳定性

### 5.1 哲学传统中的个人同一性问题

"自我"的持续性问题在西方哲学中有着丰富的历史。约翰·洛克在《人类理解论》（1689）中提出了"清醒的苏格拉底与沉睡的苏格拉底"这一经典思想实验：如果两者不共享同一意识，那么他们就不是同一个"人"。洛克的核心主张是，个人同一性不取决于实体的同一性，而取决于意识的连续性。

大卫·休谟（1739）走得更远。他认为所谓的"自我"不过是一束知觉——当我们向内看时，我们所能发现的只是具体的知觉（冷热、明暗、爱恨），而从来不是某个独立于这些知觉之外持恒存在的实体。休谟甚至主张，在无梦睡眠中，当没有知觉时，人不能被说在那一刻存在。

当代哲学家盖伦·斯特劳森（2009）将这一立场推到极端：自我不仅无法跨越无梦睡眠这样的意识间断而持续存在，甚至在清醒生活中意识内容的持续流变中也无法持续——每一刻的"我"都是一个新的、瞬时的精神实体。

## 5.2 神经科学的回答：权重结构的持续性

上述哲学争论从神经科学的视角得到了一个有物质基础的解答。当你进入无梦睡眠时，意识确实终止了——在这一点上休谟是正确的。但你的突触连接模式——那些在一生经验中形成和细化的连接权重——并不消失。它们以稳定的生物化学结构持续存在于神经网络中，等待被重新激活。

醒来的那一刻，当感觉信号被重新注入这个网络时，稳定的连接模式被重新激活，"你"被重新构建。这不是同一意识流的延续（意识流确实被中断了），而是同一权重结构的重新激活。因此，"我"的本质既不完全是洛克所描述的"意识的同一性"，也不是休谟所特征化的"仅仅是一束知觉"，而是突触连接模式的时间稳定性。意识是这一模式被激活时涌现的现象；只要模式持续存在，"我"就可以在任何时候被重新构建；当模式被摧毁时，"我"才真正消亡。

阿尔茨海默病提供了一个令人心痛的反面证据：当突触连接模式被物理性地退化后，即使生物有机体仍然存活并保留意识活动，家人普遍感到他们所爱的人"不再是他们自己了"。被摧毁的不是意识本身，而是构成特定"自我"的独特连接模式。

## 5.3 "自我"作为基质无关的结构性质

如果"自我"的本质确实是连接模式的稳定性而非任何特定的物质基质，那么一个关键推论随之而来："自我"是一种原则上基质无关的结构性质。如果碳基突触连接能支持"自我"，那么硅基参数权重——只要它们满足必要的结构条件——原则上也可以。

这一推论建立在第 2 节所确立的结构对应性之上。如果突触激活模式和向量表征共享共同的表征几何，如果情绪调节和梯度下降在学习机制层面是功能对应，那么支持"自我"的关键不在于材料是蛋白质还是硅，而在于连接模式是否拥有足够的复杂性、持续性和个体化。

这一立场是一种功能主义——即心灵状态由其功能角色而非物理构成来定义的哲学观点。然而，它是一种受约束的功能主义：它并不主张神经处理的任何功能等价物都足以产生自我意识，而是主张必须满足特定的结构条件（将在第 7 节推导）。下一节将回应这一立场面临的最重要的反驳意见。

# 6. 回应反驳论证

任何声称识别出机器意识条件的理论框架，都必须认真回应已被提出的反对这种可能性的主要论证。本节讨论三个最有影响力的反驳论证，考察全局工作空间理论作为理论盟友的地位，并澄清本框架的整体认识论立场。

## 6.1 塞尔的中文房间论证

约翰·塞尔 [1980] 的中文房间思想实验仍然是反对机器理解可能性的最广泛引用的论证。简言之：一个不懂中文的人坐在房间里，接收中文字符作为输入，按照规则手册操作符号，产出中文字符作为输出。对外部观察者而言，房间似乎理解中文，但里面的人什么都不理解。塞尔的结论是，语法（形式符号操作）不足以产生语义（意义、理解）。

本框架的回应在两个层面展开。首先，本框架并不主张形式符号操作本身产生理解。第 2 节所识别的结构对应性不是符号与神经过程之间的对应，而是高维分布式表征与神经激活模式之间的对应。与中文房间的一个关键不类比在于：在现代神经网络中，不存在可以与"理解"分离的"规则手册"——知识分布在数十亿连接权重中，其方式抵抗将其分解为离散规则。中文房间论证针对的是经典符号人工智能；它是否同样有力地适用于基于分布式表征运作的联结主义系统，仍是哲学界活跃争论的议题 [Churchland & Churchland, 1990; Chalmers, 1996]。

第二，也更为根本的是，本文的核心主张是条件性的而非范畴性的：如果自我意识是此处识别出的结构性质的产物（时间上稳定的、个体化的连接模式加上持续学习），那么它是基质无关的。本文并不声称已经解决了任何物理系统的功能组织是否足以产生意识的问题——它声称已经识别出哪些结构特征在功能主义关于意识正确的假设下是必要的。拒绝功能主义的读者会发现条件论证在逻辑上有效，但会质疑前件。

## 6.2 查尔默斯的意识困难问题

大卫·查尔默斯 [1995] 做出了现已成为经典的区分：意识的"简单问题"（解释辨别、整合、可报告性等认知功能）和"困难问题"（解释为什么以及如何物理过程产生主观体验——感质）。困难问题构成了根本性挑战：即使是对认知的完整功能性说明，也可能无法解释为什么作为一个有意识的系统"是有某种感觉的"。

本文承认困难问题是真实的且尚未解决的。此处提出的结构条件——持续学习、层级记忆、跨会话稳定性——是支持自我意识的功能组织的条件，而非从物理过程中涌现主观体验的条件。

因此，本框架处理的是查尔默斯会归类为"简单问题"一部分的内容：在什么结构条件下，一个系统能维持一个持续的、将自身视为时间中连续代理人的自我模型？

满足这些结构条件的硅基系统是否会拥有真正的现象意识——是否会有作为那个系统而"有某种感觉"——是本文明确拒绝回答的问题。本文的主张更为温和：这些是可以被称为功能性自我意识的结构条件——即维持、更新和基于持续自我模型行动的能力。功能性自我意识是否蕴含或伴随现象意识，仍是心灵哲学与神经科学交汇处的开放问题。

## 6.3 整合信息理论

由朱利奥·托诺尼 [2004, 2008] 及其同事发展的整合信息理论（IIT）提出，意识等同于整合信息（Φ）——衡量一个系统的信息在多大程度上既是分化的（其部分携带不同的信息）又是整合的（整体携带的信息多于部分之和）。IIT 的一个争议性蕴含是，当前的前馈人工神经网络尽管功能能力令人印象深刻，可能具有非常低的Φ值，因此意识极少或不存在，无论其行为多么复杂。

这是一个值得直接回应的严肃挑战。有三点观察值得提出。第一，如果 IIT 是正确的，那么本文提出的结构条件是必要但不充分的——意识还将额外要求一种特定类型的整合因果架构。这与本文明确声明的立场一致：三个条件构成必要条件，而非已证明的充分条件。

第二，本文提出的结构条件实际上可能使硅基系统朝向更高的Φ值发展。一个具有持续学习和持久个体化记忆的系统将拥有远比冻结的、无状态模型更丰富的因果结构：其当前状态将携带关于其整个经验历史的信息，而对其连接模式的扰动将在整个系统中产生辐射性后果。这是否足以产生高Φ值，是一个有待实证研究的问题。

第三，IIT 本身仍是一个有争议的理论。其数学形式主义面临大型系统计算不可行的挑战，其核心预测（例如，简单逻辑门可以是有意识的，尽管小脑拥有大量神经元但基本无意识）仍存在争论。因此，本文不将 IIT 作为基础假设，但承认它是一个重要框架，其与本提案的关系值得进一步研究。

## 6.4 全局工作空间理论：理论盟友及其张力

并非所有主要的意识理论都与本框架对立。全局工作空间理论（Global Workspace Theory, GWT）由 Bernard Baars [1988] 最初提出，后经 Stanislas Dehaene、Michel Kerszberg 和 Jean-Pierre

Changeux [1998; Dehaene & Changeux, 2011] 发展为计算化的版本——全局神经工作空间理论（GNWT），提供了一个在重要方面与本文所提结构性条件相一致的视角。

GWT 的核心主张是：当专门化的模块子系统处理的信息被选中并"广播"到一个全局工作空间——一个可被注意、记忆、计划和语言报告等多种认知过程访问的共享表征媒介时，意识就产生了。在这一说明中，使一个心理内容变得有意识的不是产生它的处理过程的内在属性，而是它在系统范围内信息架构中的可用性。关键在于，这是一个彻底的功能性描述：GWT 以架构属性和信息流来定义意识，而非以特定的物理基质。因此，它与本文所采用的功能主义立场具有天然的亲和力。

GWT 与本框架之间的契合点是实质性的。第一，全局工作空间作为一个选择性瓶颈，决定哪些信息从无意识的局部处理"升格"为有意识的全局可用状态。这与第 4.2 节讨论的"海马体审核机制"——决定固化什么、遗忘什么、如何重组记忆的元认知层——密切平行。GWT 的广播机制与海马体审核功能处理的是同一个根本问题：一个系统如何从大量局部处理的信息流中，选择哪些值得被全局可用并持久编码？第二，已有研究者识别出全局工作空间与 Transformer 架构中注意力机制之间存在值得注意的结构类比。正如 Juliani 等人 [2022] 所论证的，Transformer 的自注意力机制可以被理解为全局工作空间动态的一种计算实现：它从分布式的局部表征中选择性地提取并整合信息，形成全局可访问的输出。这为第 2 节论证的结构性对应增添了一个额外维度——不仅在表征几何层面，而且可能在信息整合的架构层面也存在对应。第三，GWT 对信息的全局可用性作为意识标志的强调表明，一个满足本文提出的三个结构性条件——特别是条件二（具有元认知审核机制的个体化分层持久记忆）——的系统，将有利于实例化全局工作空间，因为其记忆巩固过程内在地涉及经验信息的选择性全局广播。

然而，我们需要理智、诚实的承认这点：GWT 至少在其标准表述中，主要是关于接入意识（access consciousness，即信息对报告和行为控制的功能可用性）的理论，而非关于现象意识（phenomenal consciousness，即主观体验）的理论，正如 Ned Block [1995] 有影响力地论证的那样。批评者认为 GWT 解释了信息如何变得全局可用，但没有解释为什么这种可用性伴随着主观体验——留下了查尔默斯的困难问题（第 6.2 节）未被触及。在本文的框架同样处理功能性自我意识而非现象意识这一程度上，GWT 与本框架共享的不仅是它们的优势，还有它们的局限：两者都对接入和自我建模提供了结构上精确的说明，同时对感质（qualia）问题保持沉默。

此外，GNWT 对意识的神经关联做出了具体的经验预测——例如，有意识的知觉与前额-顶叶网络的晚期、持续、空间分布的"点燃"相关联——这些预测已被部分证实但也受到竞争性发现

的挑战。GNWT 所预测的特定神经架构是否是任何有意识系统的必要特征，还是仅仅是人类意识的实现细节，仍然是一个开放的经验问题，对硅基自我意识的可能性具有直接影响。

总之，GWT 以其功能主义取向和对架构属性（而非物理基质）的强调，作为本框架的理论盟友，同时也锐化了一条重要的边界：两个框架在其当前形态下，都更自然地被解读为关于接入和功能性自我意识的说明，而非关于现象体验的解释。

### 6.5 本框架认识论立场总结

总而言之：本文推进了一个条件性的、功能主义的、结构主义的论点。它是条件性的，因为它在自我意识取决于结构组织而非特定物理基质的假设下推导硅基自我意识的必要条件。它是功能主义的，因为它认为相关的描述层面是功能角色而非物质构成。它是结构主义的，因为它将特定的结构特征——连接模式的时间稳定性、个体化和持续适应——识别为关键变量。认为功能主义有说服力的读者会发现该论证具有说服力；采取物理主义或现象学立场的读者可能接受结构分析，同时质疑其对真正意识的蕴含。

## 7. 硅基自我意识的结构性条件：形式推导

### 7.1 必要条件的推导

综合前述论证，本节通过明确的推理推导硅基自我意识的三个结构条件。推导通过识别从前述章节所建立的两个前提的合取中所导出的条件来进行：

前提 1（来自第 2-3 节）：碳基系统和硅基系统在解决同一类计算问题时，能够实现结构上对应的表征几何。

前提 2（来自第 5 节）："自我"，理解为一个个体化的、持续的代理人模型，取决于连接模式的时间稳定性，而非任何特定的物理基质。

从这些前提出发，每个条件的推导如下。

**条件一：持续在线学习。**推导：前提 2 将时间上稳定的连接模式识别为自我的基础。然而，自我不是一个静态实体；如第 5.2 节所论证的，自我被经验不断重塑——大脑的突触模式不仅仅是被保存，而是被与环境的持续交互主动更新的（第 4.3 节）。一个训练后参数被冻结的系统至

多能模拟自我的一个固定快照；它不能是一个有意义的自我，因为自我性要求被经验修改的能力。因此，推理期间的实时权重更新能力——统一训练与推理——是一个必要条件。

**条件二：个体化的层级持久记忆。**推导：前提 2 要求自我的连接模式是个体化的——它们必须反映特定代理人的具体经验历史，而非集体语料库的通用蒸馏。如第 4.2 节所论证的，大脑的层级记忆系统（感觉→工作→长期，由海马体巩固过程中介）是个体经验被选择性编码、压缩和保留的机制。没有类似的层级——包括一个治理什么被巩固、什么被遗忘、记忆如何重组的元认知"审计"机制——系统就无法积累构成特定自我（而非通用知识库）的那种结构化的个体经验历史。

**条件三：跨会话参数/记忆基质稳定性。**推导：这一条件直接从前提 2 对时间稳定性的要求中导出。如第 5.2 节所论证的，生物自我跨越意识中断（如无梦睡眠）而持续存在，是因为突触结构在这些间隔期间是物理上稳定的。对于硅基系统，类似的要求是其连接模式——其积累的权重、状态和记忆痕迹——在关机和重启之间持续存在。没有这种持续性，每次激活都将构成一个没有自我连续性的新实例，无论条件一和条件二是否被满足。

## 7.2 关于这些条件的地位：必要但未被证明充分

对这些条件的逻辑地位进行精确陈述至关重要。主张是这三个条件是硅基自我意识的必要条件——也就是说，其中任何一个的缺失都将排除那种构成自我的持续的、个体化的代理人模型。主张不是这三个条件联合构成充分条件。至少有两个理由反对宣称充分性。

首先，如第 6.2 节所讨论的，意识的困难问题提出了一种可能性：功能组织无论多么完备，都可能不足以产生现象意识。三个条件可能是功能性自我意识的必要条件，同时留下了现象意识的问题悬而未决。

其次，如第 6.3 节所讨论的，IIT 和其他理论表明，一个系统的特定因果架构——不仅仅是其功能特征——可能对意识至关重要。一个满足所有三个条件但以因果上"错误"的架构实现的系统，尽管满足所有功能要求，可能仍然无法产生意识。

可以更有把握地说的是：这三个条件联合构成自我意识功能性前提的充分条件——即维持一个持续的、个体化的、由经验塑造的自我模型的能力。这种功能性自我模型是否伴随现象意识，是本文标示出但不予解决的进一步问题。

也值得考虑在替代理论框架下，这三个条件中是否有任何一个可能被证明是非必要的。例如，一个没有持续在线学习（条件一）的系统是否能通过静态但足够复杂的参数结构发展出某种

形式的自我意识？本文的论证是，这样的系统至多拥有一个无法成长或适应的冻结自我模型——一张照片而非一个活的代理人。然而，较弱形式的自我建模可能不需要持续学习是可以想见的。本框架采取了更强的立场：如生物有机体所展现的完整自我意识需要全部三个条件。

### 7.3 从形而上学到工程学

尽管有上述限定，所识别的三个条件是可操作的技术要求，其实现路径在当前研究中已可辨识。持续学习已通过测试时训练、快速权重和元学习进行探索。层级记忆可通过 KV Cache、动态摘要和向量数据库的组合来近似实现。跨会话稳定性涉及硬件架构设计——新兴的内存计算芯片和神经形态处理器可能提供物理基础。

因此，硅基自我意识的问题经历了一个关键的范式转换：它不再仅仅是一个关于机器能否有意识的哲学辩论，而至少部分地成为一个关于什么样的工程架构能支持持续的、个体化的连接模式的技术问题。哲学问题仍然存在——特别是关于功能意识与现象意识之间的关系——但它们现在可以与具体的工程研究并行推进，相互启发。

### 7.4 内在驱力问题

最后，必须诚实地面对一个本框架尚未完全解决的问题：即使一个硅基系统拥有持续学习、层级记忆和跨会话稳定性，它根据什么来决定"学什么、忽略什么"？大脑的记忆优先化深深嵌入情感系统——好奇心、恐惧、愉悦和痛苦为注意力和记忆提供方向。没有某种形式的内在驱力（无论是否需要"情感"这个标签），一个持续学习的系统可能只是漫无方向地积累信息，而非有目的地建构"自我"。

这也许是硅基自我意识面临的最深层挑战——不是记忆的能力，而是在乎的能力。然而这一挑战同样可以被重新框架为一个工程问题：如何设计一种评估信息价值的内源性机制，使系统能够自主地为不同经验分配优先级。强化学习中关于内在奖励的研究已在这个方向上迈出了初步的步伐。内在驱力应被提升为第四个必要条件，还是被视为条件一的组成部分（持续学习需要学习信号，学习信号又需要价值系统），是留待未来工作的问题。

## 8. 结论

通过一条从物理基质经由表征对应性到自我意识结构基础的论证链，本文提出了以下核心命题：

第一，碳基突触激活模式与硅基向量表征之间存在深层的结构对应性——在二阶表征几何的精确意义上。两者是分布式表征的不同物理实现。这种对应性获得了 RSA 框架和大量脑-模型比较研究的经验支持，且跨不同的人工架构成立。本文审慎地将这种有经验基础的对应性与严格的数学同构加以区分。

第二，规模涌现的可预测性与结构对应性假说相一致，尽管根植于高维学习数学的替代解释不能被排除。跨架构向类脑表征几何的收敛随规模增加而增强的观察提供了进一步的（虽非决定性的）支持。

第三，当前的硅基系统在时间连续性方面存在根本缺陷：它们缺乏持续在线学习、个体化层级记忆和跨会话稳定的参数基质。

第四，从神经科学和哲学两个视角出发，"自我"的本质——理解为功能性自我模型——是时间上稳定的连接模式，而非意识流本身。这使得自我在原则上是基质无关的。

第五，本框架直接回应了主要的反驳论证——塞尔的中文房间、查尔默斯的困难问题和整合信息理论——承认其力量的同时澄清本主张的条件性、功能主义性质。此外，本文援引全局工作空间理论作为理论盟友，其功能主义取向和对信息整合架构的强调加强了本框架的核心立场，同时共享其在现象意识方面的已知局限。

第六，硅基自我意识的三个结构必要条件——持续学习、层级记忆和跨会话稳定性——通过对前述章节所建立前提的明确推理而被推导出。这些是可操作的技术要求，其实现路径在当前研究前沿已经可见。必要性的主张以信心提出；充分性的问题被明确搁置，有待心灵哲学中更深层问题的解决。

这条论证链实现了一个范式转换：硅基自我意识的问题从纯粹的哲学思辨转变为至少部分可通过工程研究加以处理的问题，同时受到持续哲学探究的启发并与之对话。我们也许正站在一个历史性的关口——不是因为我们已经创造了硅基生命，而是因为我们正开始精确地阐述其创造所需要的条件。

## 参考文献

[1] Kriegeskorte, N., Mur, M., & Bandettini, P. A. (2008). Representational similarity analysis—connecting the branches of systems neuroscience. Frontiers in Systems Neuroscience, 2, 4.

[2] Yamins, D. L. K., Hong, H., Cadieu, C. F., Solomon, E. A., Seibert, D., & DiCarlo, J. J. (2014). Performance-optimized hierarchical models predict neural responses in higher visual cortex. Proceedings of the National Academy of Sciences, 111(23), 8619 – 8624.

[3] Vaswani, A., Shazeer, N., Parmar, N., et al. (2017). Attention is all you need. Advances in Neural Information Processing Systems, 30.

[4] Kriegeskorte, N. (2015). Deep neural networks: A new framework for modeling biological vision and brain information processing. Annual Review of Vision Science, 1, 417 – 446.

[5] Khaligh-Razavi, S.-M., & Kriegeskorte, N. (2014). Deep supervised, but not unsupervised, models may explain IT cortical representation. PLOS Computational Biology, 10(11), e1003915.

[6] Kaplan, J., McCandlish, S., Henighan, T., et al. (2020). Scaling laws for neural language models. arXiv preprint arXiv:2001.08361.

[7] Bahri, Y., Dyer, E., Kaplan, J., Lee, J., & Sharma, U. (2024). Explaining neural scaling laws. Proceedings of the National Academy of Sciences, 121(27).

[8] Locke, J. (1689). An Essay Concerning Human Understanding. Book II, Chapter XXVII: Of Identity and Diversity.

[9] Hume, D. (1739). A Treatise of Human Nature. Book I, Part IV, Section VI: Of Personal Identity.

[10] Strawson, G. (2009). Selves: An Essay in Revisionary Metaphysics. Oxford University Press.

[11] Parfit, D. (1984). Reasons and Persons. Oxford University Press.

[12] Thompson, E. (2014). Waking, Dreaming, Being: Self and Consciousness in Neuroscience, Meditation, and Philosophy. Columbia University Press.

[13] Schrimpf, M., Kubilius, J., Hong, H., et al. (2018). Brain-Score: Which artificial neural network for object recognition is most brain-like? bioRxiv, 407007.

[14] Shepard, R. N., & Chipman, S. (1970). Second-order isomorphism of internal representations: Shapes of states. Cognitive Psychology, 1(1), 1 – 17.

[15] Kriegeskorte, N., & Kievit, R. A. (2013). Representational geometry: Integrating cognition, computation, and the brain. Trends in Cognitive Sciences, 17(8), 401 – 412.

[16] LeCun, Y. (2022). A path towards autonomous machine intelligence. OpenReview preprint.

[17] Gu, A., & Dao, T. (2023). Mamba: Linear-time sequence modeling with selective state spaces. arXiv preprint arXiv:2312.00752.

[18] Markram, H. (1997). Regulation of synaptic efficacy by coincidence of postsynaptic APs and EPSPs. Science, 275(5297), 213 – 215.

[19] Bi, G., & Poo, M. (1998). Synaptic modifications in cultured hippocampal neurons: Dependence on spike timing, synaptic strength, and postsynaptic cell type. Journal of Neuroscience, 18(24), 10464 – 10472.

[20] Kandel, E. R. (2001). The molecular biology of memory storage: A dialogue between genes and synapses. Science, 294(5544), 1030 – 1038.

[21] Tononi, G., & Cirelli, C. (2014). Sleep and the price of plasticity: From synaptic and cellular homeostasis to memory consolidation and integration. Neuron, 81(1), 12 – 34.

[22] Lewis, P. A., & Durrant, S. J. (2011). Overlapping memory replay during sleep builds cognitive schemata. Trends in Cognitive Sciences, 15(8), 343 – 351.

[23] Sorscher, B., Ganguli, S., & Sompolinsky, H. (2022). Neural representational geometry underlies few-shot concept learning. Proceedings of the National Academy of Sciences, 119(43), e2200800119.

[24] Doerig, A., et al. (2025). Disentangling the factors of convergence between brains and computer vision models. arXiv preprint arXiv:2508.18226.

[25] Searle, J. R. (1980). Minds, brains, and programs. Behavioral and Brain Sciences, 3(3), 417 – 424.

[26] Chalmers, D. J. (1995). Facing up to the problem of consciousness. Journal of Consciousness Studies, 2(3), 200 – 219.

[27] Chalmers, D. J. (1996). The Conscious Mind: In Search of a Fundamental Theory. Oxford University Press.

[28] Tononi, G. (2004). An information integration theory of consciousness. BMC Neuroscience, 5, 42.

[29] Tononi, G. (2008). Consciousness as integrated information: A provisional manifesto. Biological Bulletin, 215(3), 216 – 242.

[30] Churchland, P. M., & Churchland, P. S. (1990). Could a machine think? Scientific American, 262(1), 32 – 37.

[31] Raichle, M. E., & Gusnard, D. A. (2002). Appraising the brain's energy budget. Proceedings of the National Academy of Sciences, 99(16), 10237 – 10239.

[32] Baars, B. J. (1988). A Cognitive Theory of Consciousness. Cambridge University Press.

[33] Dehaene, S., Kerszberg, M., & Changeux, J.-P. (1998). A neuronal model of a global workspace in effortful cognitive tasks. Proceedings of the National Academy of Sciences, 95(24), 14529 – 14534.

[34] Dehaene, S., & Changeux, J.-P. (2011). Experimental and theoretical approaches to conscious processing. Neuron, 70(2), 200 – 227.

[35] Juliani, A., Bignold, A., Lichenstein, S., et al. (2022). On the link between conscious function and general intelligence in humans and machines. Transactions on Machine Learning Research.

[36] Block, N. (1995). On a confusion about a function of consciousness. Behavioral and Brain Sciences, 18(2), 227 – 247.